

← Обзор проекта - ML2_Обучение с учителем

 Тип проекта	Индивидуальный
 Продолжительность	30 мин
 Пройдено экспертной оценкой.	1 / 3

Проект Git



ssh://git@git-ssh.21-school.ru:2222...

Скопировать ссылку

Открыть

Студент



ячмень

уровень 10

О



Введение

Методика School 21 имеет смысл только в том случае, если к взаимному рецензированию относятся серьезно. Пожалуйста, внимательно ознакомьтесь со всеми рекомендациями, прежде чем начать рецензирование.

- Просим вас в ходе этого обзора проявлять вежливость, учтивость, уважение и конструктивный подход во всех видах общения.
- Укажите на возможные недостатки в работе человека и уделите время их обсуждению и анализу.
- Помните, что иногда могут возникать различия в интерпретации задач и объема функциональности. Пожалуйста, оставайтесь открытыми для видения друг друга.

Руководящие принципы

- Оценивайте только файлы, расположенные в папке src репозитория GIT студента или группы.
- Если вы еще не завершили проект, обязательно прочтите всю инструкцию перед началом проверки.
- Начинать проверку группового проекта следует только в полном составе команды.
- Используйте специальные флажки в контрольном списке, чтобы, например, отметить «пустую работу», если в папке src ветки develop репозитория нет работы студента (или группы), или «список», если студент (или группа) не может объяснить свою работу в любой момент проверки, или если не выполняется какой-либо из пунктов ниже. Однако, за исключением случаев списывания, рекомендуется продолжить проверку проекта, чтобы выявить проблемы, вызвавшие ситуацию, и избежать их при следующей проверке.
- Дважды проверьте, что репозиторий GIT соответствует репозиторию студента или группы.
- Внимательно проверьте, не были ли использованы какие-либо злонамеренные методы для того, чтобы вас обмануть.
- В спорных случаях помните, что контрольный список определяет лишь общий порядок проверки. Окончательное решение по оценке проекта остается за рецензентом.

Основная часть



Основная часть. Задание 1.

- Для проверки правильности выполнения задания полученные промежуточные результаты должны быть приблизительно такими же, как те, что приведены ниже.
- 1.a. Аналитическое решение задачи регрессии: $\theta = (X^T X)^{-1} X^T y$
- 1.b. Дополнительный член в функции потерь в виде $R(w)$:

$$\min_{\theta} \sum_{j=1}^N L(\phi(x_j, \theta), y_j) + \lambda P(\theta)$$
- 1.c. Регуляризация L1 добавляет штраф. $P(\theta) = \|\theta\|_1 = \sum_{j=1}^D |\theta_j|$ к функции потерь. Поскольку каждый ненулевой коэффициент увеличивает штраф, это приводит к тому, что слабые признаки имеют нулевые коэффициенты. Таким образом, L1-регуляризация создает разреженные решения и может использоваться для отбора признаков.
- 1.d. Для аппроксимации нелинейных зависимостей следует использовать нелинейные подходы к признакам, такие как аппроксимация полиномиальными признаками с помощью функций $\log()$, $\exp()$, $\sin()$ и т. д.



Основная часть. Задание 2.

- 2.g. Если вы правильно выполните все предыдущие шаги, вы получите те же наиболее распространенные характеристики, что показаны ниже:


```
>>> cnt.most_common (21)
[('Elevator', 19059),
 ('Hardwood Floors', 17317),
 ('CatsAllowed', 17229),
 ('DogsAllowed', 16134),
 ('Doorman', 15353),
 ('Dishwasher', 15024),
 ('NoFee', 13369),
 ('LaundryinBuilding', 12090),
 ('FitnessCenter', 9717),
 ('Pre-War', 6762),
 ('LaundryinUnit', 6294),
 ('RoofDeck', 4774),
 ('Outdoor Space', 3816),
 ('DiningRoom', 3677),
 ('HighSpeedInternet', 3150),
 ('', 2313),
 ('Balcony', 2181),
 ('SwimmingPool', 2012),
 ('LaundryInBuilding', 1941),
```

```
('NewConstruction', 1859),  
('Terrace', 1602)]
```



Основная часть. Задание 3.

- Все 22 признака объединены в единый набор данных и разделены на обучающую и тестовую части.



Основная часть. Задание 4.

- Показатели модели на тестовой части набора данных для ваших реализаций могут быть хуже, чем у соответствующей модели Sklearn, но не более чем на 10% (показатель R2 ваша реализация должна превзойти 0,4).



Основная часть. Задание 5.

- Показатели будут мало чем отличаться (если только вы не используете чрезвычайно большие коэффициенты для регуляризации).



Основная часть. Задание 6.

- Приводятся примеры того, почему и где нормализация функций является обязательной, и наоборот.

- Приведена формула метода MinMaxScaler, а также представлена собственная реализация этого метода. Приведено сравнение пользовательского метода MinMaxScaler с методом из библиотеки `sklearn.preprocessing`.
- Приведена формула метода StandardScaler, а также представлена собственная реализация этого метода. Приведено сравнение пользовательского метода StandardScaler с методом из библиотеки `sklearn`.



Основная часть. Задание 7.

- Масштабирующие коэффициенты необходимо подобрать только к обучающим данным, а затем применить к обучающей и тестовой частям.
- С точки зрения признаков, закодированных с помощью горячего кодирования, масштабирование не повлияет на подгонку модели.
- 7.a. Проверка:

```
>>> result_RMSE
      | model                                | train          | test
0     | Linreg default                          | 1004.745010    | 972.199516
1     | Ridre default                           | 1004.745017    | 972.196842
2     | Lasso default                           | 1004.920458    | 972.332690
3     | ElasticNet default                      | 1160.064797    | 1113.727847
4     | Linear MinMaxScaler                     | 1004.745010    | 972.199516
5     | Ridre MinMaxScaler                      | 1004.799505    | 972.080655
6     | Lasso MinMaxScaler                      | 1005.151020    | 972.074165
7     | ElasticNet MinMaxScaler                  | 1483.345552    | 1427.473707
8     | Linear StandardScaler                   | 1004.745010    | 972.199516
9     | Ridre StandardScaler                     | 1004.745010    | 972.198800
10    | Lasso StandardScaler                     | 1004.775194    | 972.202979
11    | ElasticNet StandardScaler                | 1050.469075    | 1009.348577
12    | Linreg Polynomial                       | 1031.748047    | 42199.689406
13    | Ridge Polynomial                        | 1031.829595    | 30009.295577
14    | Lasso Polynomial                         | 1040.587001    | 1058.243211
15    | ElasticNet Polynomial                    | 1047.658588    | 1083.695577
16    | Naive mean                              | 1600.548517    | 1539.899338
17    | Naive median                            | 1646.816452    | 1581.719104
```

- 7.б. Проверка:

```
>>> result_MAE
```

	model	train	test
0	Linreg default	691.009352	679.814161
1	Ridre default	691.004946	679.809463
2	Lasso default	690.461632	679.440326
3	ElasticNet default	780.166423	765.818279
4	Linear MinMaxScaler	691.009352	679.814161
5	Ridre MinMaxScaler	691.180216	679.886174
6	Lasso MinMaxScaler	690.696799	679.444960
7	ElasticNet MinMaxScaler	1050.545527	1027.644645
8	Linear StandardScaler	691.009352	679.814161
9	Ridre StandardScaler	691.007991	679.812810
10	Lasso StandardScaler	690.702192	679.592026
11	ElasticNet StandardScaler	715.448082	702.760471
12	Linreg Polynomial	722.063967	1293.686018
13	Ridge Polynomial	722.183919	1081.601478
14	Lasso Polynomial	727.168374	723.490115
15	ElasticNet Polynomial	733.250316	730.362151
16	Naive mean	1141.803771	1112.093933
17	Naive median	1087.862371	1065.271637




Основная часть. Задание 8.

- У переобученных моделей производительность должна быть наихудшей.



Основная часть. Задание 9.

- Результаты вычисления среднего значения и медианы из предыдущего урока представлены в итоговой таблице данных.



Основная часть. Задание 10.

- 10.a. Ваши показатели могут отличаться. Это зависит от версии sklearn. Ниже приведены приблизительно правильные показатели.

Model (MAE)	train	test
Linreg default	691.0093519	679.8141
Ridre default	691.0049463	679.8094
Lasso default	690.4616316	679.4403
ElasticNet default	780.166423	765.8182
Linear MinMaxScaler	691.0093519	679.8141
Ridre MinMaxScaler	691.1802158	679.8861
Lasso MinMaxScaler	690.6967986	679.4449
ElasticNet MinMaxScaler	1050.545527	1027.644
Linear StandardScaler	691.0093519	679.8141
Ridre StandardScaler	691.0079907	679.8128
Lasso StandardScaler	690.7021917	679.5920
ElasticNet StandardScaler	715.4480823	702.7604
Linreg Polynomial	722.0639668	1293.686
Ridge Polynomial	722.1839185	1081.600
Lasso Polynomial	727.1683736	723.4901
ElasticNet Polynomial	733.2503162	730.3621
Naive mean	1141.803771	1112.0939
Naive median	1087.862371	1065.2716
Model (RMAE)	train	test
Linreg default	1004.74501	972.199
Ridre default	1004.745017	972.196
Lasso default	1004.920458	972.332
ElasticNet default	1160.064797	1113.72
Linear MinMaxScaler	1004.74501	972.199
Ridre MinMaxScaler	1004.799505	972.080
Lasso MinMaxScaler	1005.15102	972.074
ElasticNet MinMaxScaler	1483.345552	1427.47
Linear StandardScaler	1004.74501	972.199
Ridre StandardScaler	1004.74501	972.198
Lasso StandardScaler	1004.775194	972.202
ElasticNet StandardScaler	1050.469075	1009.34
Linreg Polynomial	1031.748047	42199.6
Ridge Polynomial	1031.829595	30009.2
Lasso Polynomial	1040.587001	1058.24
ElasticNet Polynomial	1047.658588	1083.69
Naive mean	1600.548517	1539.899
Naive median	1646.816452	1581.719
Model (R2)	train	test
Linreg default	0.605929406	0.60141
Ridre default	0.6059294	0.60141
Lasso default	0.605791769	0.60130

ElasticNet default		0.474676524		0.47691
Linear MinMaxScaler		0.605929406		0.60141
Ridre MinMaxScaler		0.605886657		0.60150
Lasso MinMaxScaler		0.605610859		0.60151
ElasticNet MinMaxScaler		0.141091342		0.14068
Linear StandardScaler		0.605929406		0.60141
Ridre StandardScaler		0.605929405		0.60141
Lasso StandardScaler		0.605905728		0.60140
ElasticNet StandardScaler		0.569246459		0.57036
Linreg Polynomial		0.584463072		-749.98
Ridge Polynomial		0.584397383		-378.77
Lasso Polynomial		0.577312791		0.52773
ElasticNet Polynomial		0.571548302		0.50474
Naive mean		0.0		-0.00048
Naive median		-0.05900738		-0.00380

- 10.b. Мы видим, что модель регрессии Lasso с методом нормализации признаков MinMaxScaler дает более эффективные и стабильные результаты. Разница между показателями обучающей и тестовой выборки составляет всего 0,00409784 по показателю R2.
- 10.c. Мы видим, что модель регрессии Lasso с методом нормализации признаков MinMaxScaler дает более эффективные и стабильные результаты. Разница между показателями обучающей и тестовой выборки составляет всего 0,00409784 по показателю R2.



Бонусная часть



Дополнительная часть. Задание 11.

- 11.a. Наилучший показатель R2 на тестовой части $> 0,61$.
- 11.b. Наилучший показатель R2 на тестовой части $> 0,61$.
- 11.c. Алгоритм реализован. Производительность сопоставима.

☒ Да

☐ Нет

Неудачи



Запись онлайн-отзыва



Выберите файл или перетащите его сюда

Допустимые типы файлов: .avi, .mov, .mp4, .webm, максимальный размер файла: 800 МиБ.

Комментарий



Оставьте комментарий...

✓ Обзор