← Обзор проекта - ML3_Validation

Тип проекта	Индивидуальный
Продолжительность	30 мин
Пройдено экспертной оценкой.	0 / 3

Проект Git

ssh://git@git-ssh.21-school.ru:2222/students_repo/sa... Скопировать ссылку Открыть

Студент

санджайпи уровень 6

О

Основная часть

Основная часть. Задание 1.

- 1.a. Перекрестная проверка с исключением одного наблюдения (leave-one-out cross-validation) — это метод, при котором на каждом шаге для проверки отбирается только одно наблюдение. Если у нас есть N наблюдений, то мы будем обучать модель N итераций на N-1 выборках. Полученная метрика представляет собой среднее значение N метрик. Преимущества: мы многократно обучаем модель на наборе данных, содержащем N-1 наблюдений, чтобы уменьшить переобучение. Недостатки: это трудоемкая процедура для больших N.

- 1.b. Метод Grid Search принимает на вход заданные вручную диапазоны параметров и исчерпывающе ищет наилучшую комбинацию. Метод Random Search пробует случайные комбинации гиперпараметров для нахождения наилучшего решения. Байесовская оптимизация позволяет оптимизировать f(x), которая представляет собой производительность модели, при этом x — заданные гиперпараметры.
- 1.c. Метод Пирсона работает с корреляционной матрицей и позволяет удалять признаки с коэффициентами корреляции, близкими к 1. Значение хи-квадрат показывает зависимость между признаками и откликом. Чем ниже значение хи-квадрат, тем слабее зависимость. Метод регуляризации Lasso показывает признаки с коэффициентом = 0, что означает, что такие признаки можно удалить. Важность перестановок рассчитывается после подгонки модели. Затем значения признаков случайным образом перемешиваются. После этого мы оцениваем качество модели с помощью такого признака и оцениваем эффект признака.



Основная часть. Задание 2.

- Данные считываются.
- Созданы следующие характеристики: «Лифт», «Паркетные полы», «Разрешено содержание кошек», «Разрешено содержание собак», «Швейцар», «Посудомоечная машина», «Без комиссии», «Прачечная в здании», «Фитнес-центр», «Довоенная постройка», «Прачечная в квартире», «Крыша», «Открытая площадка», «Столовая», «Высокоскоростной интернет», «Балкон», «Бассейн», «Новое здание», «Терраса».



Основная часть. Задание 3.

- Все механизмы разделения реализованы. Разделение с учетом временной зависимости должно следовать правилу: максимальная временная метка обучающего набора данных < максимальная временная метка валидного набора данных < максимальная временная метка тестового набора данных. Для обеспечения детерминированного разделения задайте случайное состояние (начальное значение).



Основная часть. Задание 4.

- Все методы реализованы. Метод GroupKFold будет хранить всю группу либо в обучающей выборке, либо в тестовой части. Метод StratifiedKFold должен сохранять соотношение обучающей и тестовой выборок для каждой выборки и каждого целевого класса.



Основная часть. Задание 5.

- Для текущего набора данных методы перекрестной проверки не будут сильно отличаться. Обычный K-кратный бросок подойдет для наших целей. Но если в распределении целевой переменной присутствует «длинный хвост», лучше использовать стратифицированный K-кратный бросок и разделить дорогие дома, сохраняя соотношение обучающей и тестовой выборок. Для этого необходимо разделить непрерывную целевую переменную на интервалы.



Основная часть. Задание 6.

- 6.b. Ваши значения могут немного отличаться. Ниже приведены приблизительно правильные значения, но порядок признаков должен быть близок к правильному. Многие нулевые признаки можно удалить из модели, чтобы сделать её легче.

ИДЕНТИФИКАТОР	Имя	Важность
0	ванные комнаты	7029.665399
1	спальни	3281.652836
7	Швейцар	583.233929
22	Терраса	152.865182
8	Посудомоечная машина	142.480520
3	Лифт	95.294494
23	Эксклюзив	81.329771
12	Довоенный	56.824936
18	Балкон	11.638302
6	Собаки разрешены.	0.000000
9	Без комиссии	0.000000
...	...	...

По всем параметрам не наблюдается существенной разницы в метриках по сравнению с моделью.

МАЭ

модель	тренироватьс я	действительны й	тест
Lasso MinMaxScaler	701.342937	698.384926	705.458181
Lasso top10 MinMaxScaler	701.342697	698.384660	705.458793

RMSE

модель	тренироватьс я	действительны й	тест
Lasso MinMaxScaler	1010.979688	1022.966616	1031.492491
Lasso top10 MinMaxScaler	1010.979416	1022.966396	1031.494059

P^2

модель	тренироваться	действительный	тест
Lasso MinMaxScaler	0.593235	0.590885	0.570018
Lasso top10 MinMaxScaler	0.593235	0.590885	0.570017

- 6.d. После применения метода важности перестановок из пакета Sklearn, вы должны получить приблизительно равные значения (с использованием метрики MAE):

  neg_mean_absolute_percentage_error:

Особенность	Среднее значение ± стандартное отклонение
ванные комнаты	0,07797 ± 0,001
спальни	0,07601 ± 0,002
Швейцар	0,02999 ± 0,001
Посудомоечная машина	0,00285 ± 0,000
Лифт	0,00118 ± 0,000
Терраса	0,00036 ± 0,000
Довоенный	0,00033 ± 0,000
Эксклюзив	0,00015 ± 0,000

  А после модернизации модель получила следующие 10 главных характеристик:

  МАЭ

модель	тренироватьс я	действительн ый	тест
Lasso MinMaxScaler	701.342937	698.384926	705.458181
Lasso top10 MinMaxScaler	701.342697	698.384660	705.458793
Lasso permutation MinMaxScaler	701.336003	698.341427	705.426165

RMSE

модель	тренировать ся	действительн ый	тест
Lasso MinMaxScaler	1010.979688	1022.966616	1031.492491
Lasso top10 MinMaxScaler	1010.979416	1022.966396	1031.494059
Lasso permutation MinMaxScaler	1011.001614	1022.948425	1031.475840

P^2

модель	тренироватьс я	действительны й	тест
Lasso MinMaxScaler	0.593235	0.590885	0.570018
Lasso top10 MinMaxScaler	0.593235	0.590885	0.570017
Lasso permutation MinMaxScaler	0.593218	0.590899	0.570032

- 6.е. Метод Шапа также дает нам практически одинаковые результаты в отношении важности признаков и метрик модели:

идентификатор	особенность	shap_value
0	ванные комнаты	584.954823
1	спальни	439.289982
7	Швейцар	289.789269
8	Посудомоечная машина	69.776994
3	Лифт	47.288500

идентификатор	особенность	shap_value
12	Довоенный	16.453314
22	Терраса	12.179888
23	Эксклюзив	7.064309
18	Балкон	1.262868
16	Столовая	0.000000
21	Новое строительство	0.000000
...	...	...

А после модернизации модель получила следующие 10 главных характеристик:

МАЭ

модель	тренироватьс я	действительн ый	тест
Lasso MinMaxScaler	701.342937	698.384926	705.458181
Lasso top10 MinMaxScaler	701.342697	698.384660	705.458793
Lasso permutation MinMaxScaler	701.336003	698.341427	705.426165
Lasso shap MinMaxScaler	701.346676	698.388275	705.463295

RMSE

модель	тренировать ся	действительн ый	тест
Lasso MinMaxScaler	1010.979688	1022.966616	1031.492491
Lasso top10 MinMaxScaler	1010.979416	1022.966396	1031.494059
Lasso permutation MinMaxScaler	1011.001614	1022.948425	1031.475840
Lasso shap MinMaxScaler	1010.979168	1022.965683	1031.493563

P^2

модель	тренироватьс я	действительны й	тест
Lasso MinMaxScaler	0.593235	0.590885	0.57001 8
Lasso top10 MinMaxScaler	0.593235	0.590885	0.57001 7
Lasso permutation MinMaxScaler	0.593218	0.590899	0.57003 2
Lasso shap MinMaxScaler	0.593236	0.590885	0.57001 8



Основная часть. Задание 7.

- Для приближения к оптимальным параметрам Optuna должна выполнять меньшее количество операций.



Неудачи

Запись онлайн-отзыва

Выберите файл или перетащите его сюда

Допустимые типы файлов: .avi, .mov, .mp4, .webm, максимальный размер файла: 800 МиБ.

Комментарий

Оставьте комментарий...

Обзор